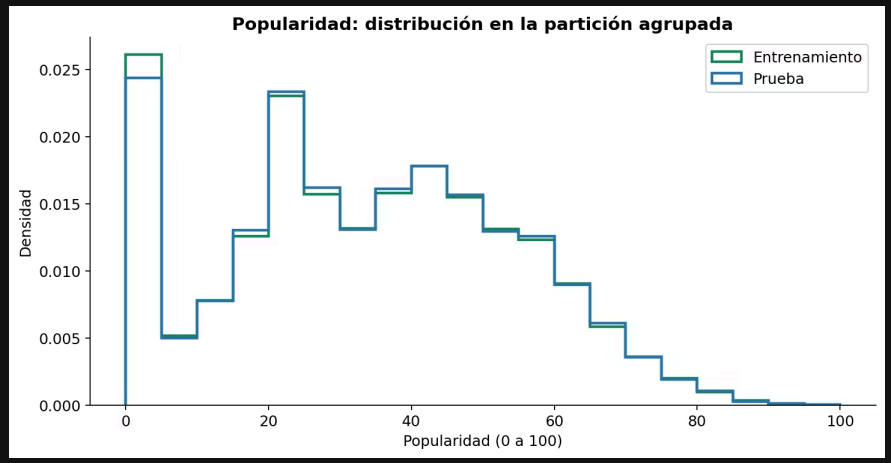
Inteligencia musical en Spotify

Estimación de popularidad observada y descubrimiento de perfiles musicales

Evaluación Parcial N.º 2 · MLY1101 · Caso C

Equipo: fluzxks · benjadiaz112 · Freymuth Christopher Isaac

Continuación de la experiencia 1

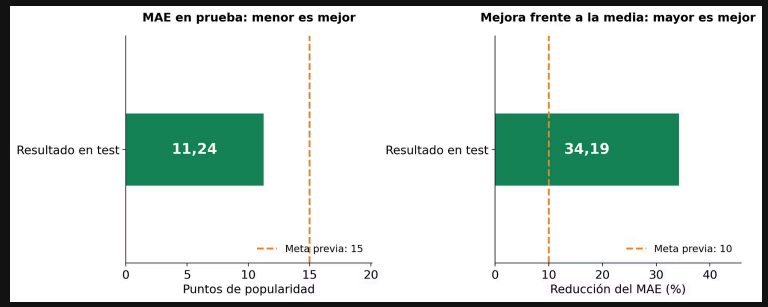


Popularidad de las canciones en entrenamiento y prueba; objetivo numérico entre 0 y 100.

Made with GAMMA

Problema de negocio y metodología

- Decisión: orientar la exploración de catálogo con revisión humana.
- Solución: regresión de popularidad observada (0–100) y segmentación de perfiles de audio.
- Metas técnicas previas: MAE ≤15 y reducción del error ≥10% frente a la media constante.
- CRISP-DM: negocio → datos → preparación → modelado → evaluación → despliegue local.
- Sin fechas ni campañas, no medimos éxito futuro ni retorno financiero.

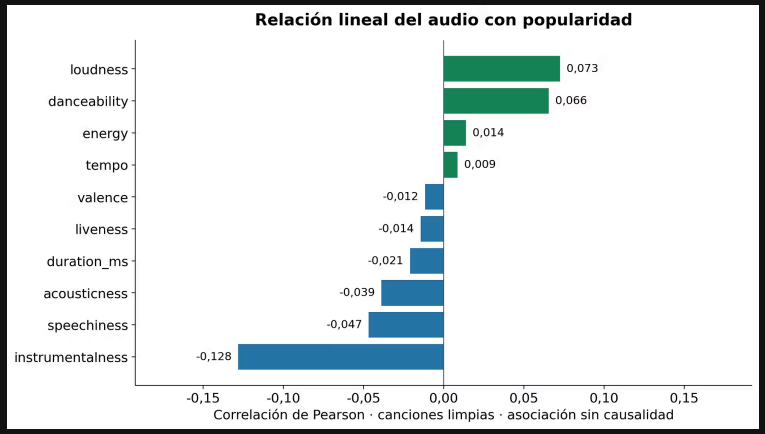


Las dos metas técnicas se cumplen en prueba: MAE 11,24 y mejora 34,19% frente a la media.

Made with GAMMA

Datos y hallazgos exploratorios

- Fuente: CSV de Spotify Tracks entregado en la experiencia 1.
- 114.000 filas y 21 columnas originales; 89.741 IDs únicos.
- Tras limpieza: 89.495 canciones, 113 géneros y cero valores nulos.
- Popularidad media: 33,20/100. Las relaciones lineales con el audio son débiles.
- Se detectaron 720 IDs con popularidades distintas: conservamos la primera observación y auditamos su sensibilidad en entrenamiento.

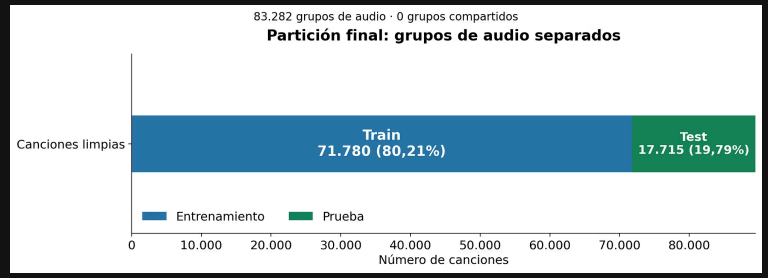


Correlaciones de Pearson con popularidad sobre el conjunto limpio; no establecen causalidad.

Made with GAMMA

Preparación y evaluación sin audio repetido

- Reutilizamos la limpieza de la experiencia 1: IDs únicos y filtros de duración y rangos de audio.
- Agrupamos versiones de audio idéntico: 6.213 filas adicionales tienen una huella de audio ya presente.
- Train: 71.780 canciones. Test: 17.715. Cero IDs o grupos de audio compartidos.
- Validación cruzada (CV) de tres folds agrupados; transformaciones ajustadas dentro de cada fold.
- Se excluyen nombres, artistas e IDs de los predictores. Test no decide el ganador.



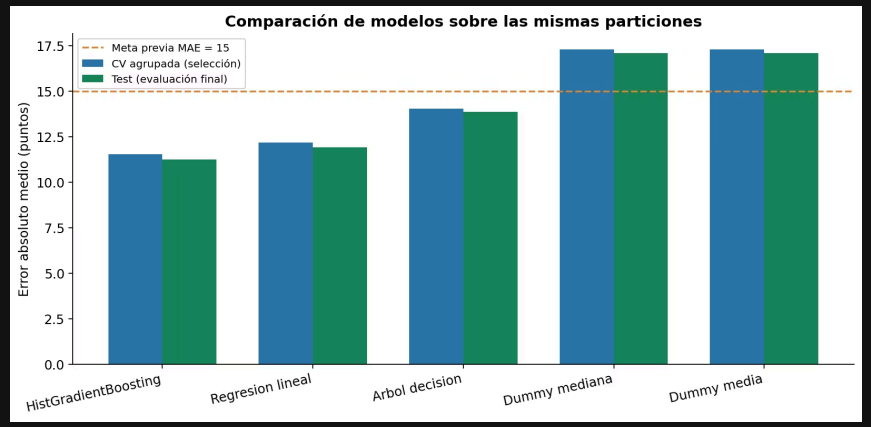
La división es 80/20 por grupos; la proporción final de canciones es aproximadamente 80,21%/19,79%.

Made with GAMMA

Comparación de modelos supervisados

- Lineal: referencia interpretable; árbol: relaciones no lineales; ensamble: suma de árboles para corregir errores.
- Ganador por MAE de CV agrupada: HistGradientBoosting, CV 11,52.
- HGB: 220 iteraciones y tasa 0,08 fijas; CV eligió 31 hojas y regularización L2=10. Se probaron 13 configuraciones.

Modelo	MAE en prueba
Media constante	17,08
Regresión lineal	11,91
Árbol de decisión	13,85
HistGradientBoosting	11,24

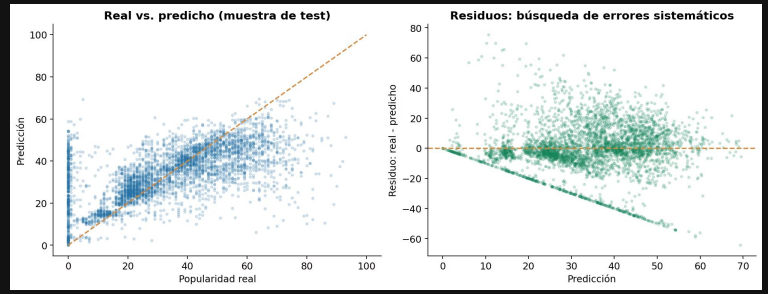


Mismos folds y reserva de prueba para todos; también se evaluó una referencia de mediana.

Made with GAMMA

Qué significa el error del modelo

- MAE 11,24: error absoluto promedio en puntos de popularidad.
- RMSE 16,23: penaliza más los errores grandes. R^2=0,369 compara variación; no es porcentaje de aciertos.
- IC del 95% por bootstrap agrupado del MAE: 10,99–11,46; condicionado a este modelo y este test.
- En popularidad 81–100, MAE 44,91 en 105 canciones: subestima los extremos.
- Este error limita su uso en decisiones automáticas de promoción.



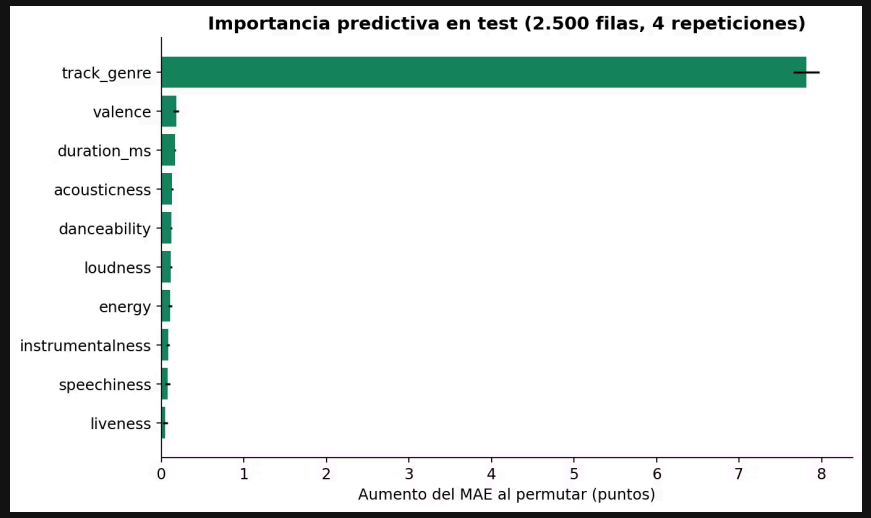
Muestra de test: popularidad real frente a predicción y residuos respecto del valor predicho.

Made with GAMMA

El género concentra buena parte de la señal

- Mejora frente a la media por género: 5,74%; frente a la constante global: 34,19%.
- Permutar género aumenta el MAE aproximadamente 7,82 puntos.
- Es importancia predictiva, no evidencia causal. La limpieza conserva una sola etiqueta de género por ID.

Comparación	MAE en prueba
Media por género, aprendida solo en train	11,93
HGB completo	11,24
HGB sin género, conservando las otras 14 variables	15,28

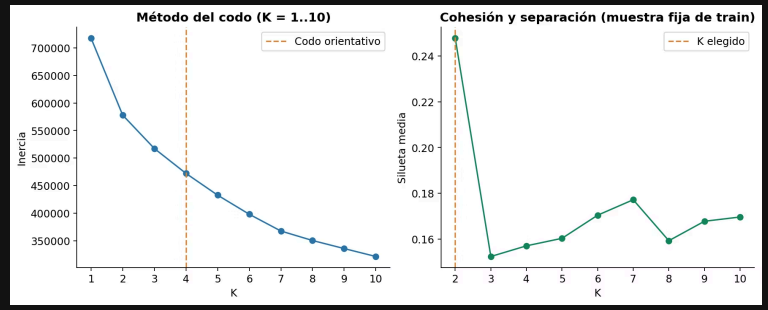


Importancia por permutación en test: muestra de 2.500 canciones, cuatro repeticiones.

Made with GAMMA

K-Means: elección del número de grupos

- Diez variables continuas de audio, estandarizadas con train; sin popularidad ni género.
- Comparamos K=1..10, con 10 inicializaciones y semilla 42.
- Regla: mayor silueta de train entre soluciones con todos los grupos ≥3%.
- Elegimos K=2: silueta de train 0,248 y de test 0,237.
- El codo sugiere K=4, alternativa también perfilada. La separación es limitada.
- Semillas alternativas: ARI≈0,997; estabilidad no equivale a separación perfecta.

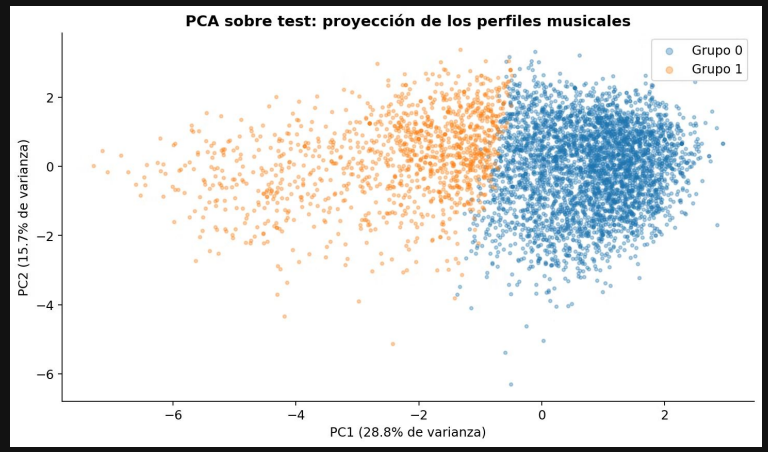


Codo y silueta no señalan el mismo K; se aplica la regla declarada de selección.

Made with GAMMA

Perfiles musicales y alcance de PCA

- Grupo 0, relativamente energético: 75,3% de train; energía 0,75, acústica 0,19 y tempo 126,2 BPM.
- Grupo 1, relativamente acústico: 24,7%; energía 0,30, acústica 0,76 y tempo 109,9 BPM.
- Uso propuesto: explorar selecciones de actividad o tranquilas con revisión de curaduría. Son nombres descriptivos, no estilos certificados.
- Dos componentes PCA conservan 44,44% de varianza; se necesitan seis para llegar al 80%.

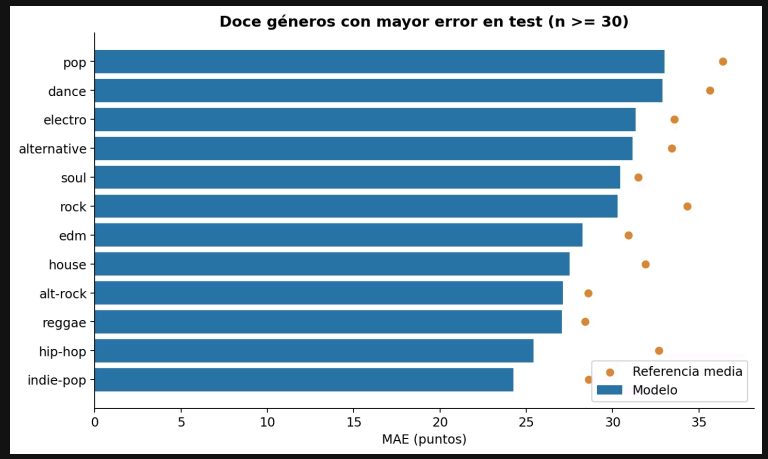


PCA ajustado en train y aplicado a test: mapa parcial, con superposición entre grupos.

Made with GAMMA

Conclusión y piloto propuesto

- El modelo apoya consulta de catálogo; el género y los errores altos en extremos limitan las recomendaciones.
- Popularidad no equivale a mérito. Las diferencias por género requieren revisión humana y no prueban discriminación ni causalidad.
- Piloto propuesto, aún no ejecutado: dos semanas y 12 pares de sesiones.
- Metas comerciales propuestas: reducción mediana del tiempo ≥15%, aceptación agregada ≥70% y pérdida mediana de cobertura de géneros ≤5 puntos porcentuales.
- Antes de uso comercial: validar derechos de uso, conseguir datos recientes y evaluar con una prueba temporal.



Géneros con mayor MAE en test entre los que tienen al menos 30 casos; son diferencias descriptivas.

Made with GAMMA